

مستندات معماری و مهندسی سیستم ربات تحلیلگر یوتیوب

تشریح جامع بستر پردازش تمام‌ابری (Serverless)، چرخه استنتاج چندوجهی، ساختار پرامپت‌های پروداکشن، اقتصاد توکن‌ها و راهکارهای حل چالش‌های سیستمی.

محیط اجرا (Runtime):

موتور هوش مصنوعی:

پایگاه داده لبه (Storage):

Cloudflare Workers KV

Google Gemini Flash 2.5/3.5

Cloudflare Workers (V8)

رابط کاربری (Interface):

Telegram Bot API (HTML)

۱. معماری کلان سیستم و جریان تبادل داده (Architecture)

این سامانه مبتنی بر معماری نوین پردازش ابری لبه (Edge Computing) طراحی شده است. هیچ سرور اختصاصی سنتی درگیر نبوده و کل منطق برنامه به عنوان یک میکروتابع درون شبکه‌ای از ۳۳۰ نقطه حضور (PoP) در سراسر دنیا توزیع شده است. این رویکرد زمان آغاز به کار را به صفر رسانده و تاخیر شبکه را برای کاربران پیام‌رسان تلگرام به حداقل می‌رساند.

```
+-----+ 1. Webhook POST +-----+ | Telegram User | ---  
-----> | Cloudflare Worker (Edge) | | (Mobile/Desktop App) | <-----  
----- | (youtube-analyzer-bot) | +-----+ 8. Multi-Chunk Messages +-  
-----+ | ^ | 2. Read / Write Cache | | +-----+ | | v | |  
+-----+ 3. Metadata | | Cloudflare KV Store | Fetch | | | (BOT_KV) | v |  
+-----+ +-----+ | | YouTube oEmbed/DOM | +-----+  
-+ | | 4. Direct fileUri Stream | v +-----+ | Google Gemini 2.5/3.5 |  
| (Generative Language API) | +-----+
```

چرخه حیات یک درخواست از آغاز تا تحویل (Request Pipeline)

۱. دریافت وب‌هوک و ارزیابی دسترسی: پیام ارسالی کاربر با متد POST وارد ورکر می‌شود. ابتدا شناسه تلگرام کاربر در پایگاه داده لبه با ساختار لیست سفید (Whitelist) اعتبارسنجی می‌شود.

۲. نرمال‌سازی پیوند: تابع extractYouTubeUrl شناسه ۱۱ کاراکتری اثر را از تمام ساختارهای استاندارد یوتیوب، پیوندهای کوتاه، ویدیوهای عمودی (Shorts) و آدرس‌های جاسازی‌شده تفکیک می‌کند.

3. استخراج فراداده (Metadata Fetch): مشخصات عمومی از طریق YouTube oEmbed دریافت شده و طول دقیق به ثانیه از طریق پارس کردن متاتگ‌های صفحه یوتیوب واکشی می‌گردد.
4. ارزیابی کش لبه (Edge Cache Hit): کلید `cache_{mode}_{videoId}` در دیتابیس KV بررسی می‌شود. در صورت ثبت قبلی، تحلیل ظرف ۳۰ میلی‌ثانیه بدون مصرف توکن به کاربر تحویل می‌گردد.
5. ترکیب پرامپت و تثبیت زمانی: زمان دقیق اثر محاسبه شده و همراه با دستورالعمل‌های ضد توهم به قالب پرامپت تزریق می‌شود.
6. فراخوانی چندوجهی جمناي: لینک ویدیو بدون نیاز به دانلود روی سرور، مستقیماً از طریق `fileData` برای پردازش همزمان تصویر و صوت تحویل داده می‌شود.
7. پالایش HTML تلگرام: خروجی مدل پاکسازی شده و تایم‌استمپ‌های [MM:SS] به لینک‌های رسمی با قابلیت پرش به همان ثانیه ویدیو در یوتیوب تبدیل می‌شوند.
8. قطعه‌بندی و تحویل نهایی: در صورت عبور طول متن از سقف مجاز تلگرام، محتوا به صورت پاراگراف‌بندی‌شده و پیوسته در چند پیام متوالی به کاربر ارسال می‌گردد.

۲. ارتباط با Google Gemini API و ساختار ورودی/خروجی

ارتباط با موتور هوش مصنوعی از طریق نقطه پایانی `v1beta/models/gemini-2.5-flash:generateContent` انجام می‌پذیرد. ساختار ارسال درخواست به صورت خام به شرح زیر است:

```
{
  "contents": [
    {
      "parts": [
        {
          "fileData": {
            "fileUri": "https://www.youtube.com/watch?v=s1Xxxxxxx",
            "mimeType": "video/*"
          }
        },
        {
          "text": "دستورالعمل کامل سیستم و پرامپت تحلیل به زبان فارسی"
        }
      ]
    }
  ],
  "generationConfig": {
    "temperature": 0.3,
    "topK": 40,
    "topP": 0.95
  }
}
```

محاسبات ریاضی اقتصاد توکن‌ها (Token Economics)

طبق اسناد مهندسی Google AI Studio، پردازش مستقیم فایل‌های ویدیویی یوتیوب ترکیبی از دو جریان بصری و صوتی مجزاست:

بخش رسانه‌ای	نرخ نمونه‌برداری	نرخ مصرف توکن ورودی
فریم‌های تصویر (Video) (Frames)	۱ فریم بر ثانیه (FPS 1)	۱۰۰ الی ۲۶۳ توکن در هر ثانیه
جریان صوتی (Audio Track)	پیوسته (۱۶ کیلوهرتز)	۳۲ توکن در هر ثانیه
مجموع متوسط نرخ ورودی	تصویر + صوت ترکیبی	۲۹۵ توکن در ثانیه (~۱۷,۷۰۰ توکن در دقیقه)

⚠️ علت فنی خطای توقف در دقیقه ۱۵ در پلن استاندارد گوگل:

پلن رایگان Google AI Studio دارای سقف ۲۵۰,۰۰۰ توکن در دقیقه (TPM) است. یک ویدیوی ۱۴ دقیقه‌ای حدود ۲۴۸,۰۰۰ توکن مصرف می‌کند. بنابراین در دقیقه ۱۵ سقف سهمیه پر شده و خطای HTTP 429 (ResourceExhausted) رخ می‌دهد.

۳. متن دقیق پرامپت‌های تولیدی در پروداکشن (Production Prompts)

پرامپت‌های این سامانه حاصل مهندسی دقیق معکوس برای به حداقل رساندن توهم هوش مصنوعی (Zero Hallucination)، واقع‌گرایی مطلق و جلوگیری از ربط دادن ویدیوهای عجیب به اخبار نامربوط است.

حالت اول: خلاصه کوتاه و سریع (Quick Mode)

Prompt Mode: Quick

حالت خلاصه سازی سریع و فشرده

شما یک دستیار هوشمند و تیزبین محتوای یوتیوب هستید.

مشخصات ویدیو:

عنوان: "{meta.title}\$"

سازنده / کانال: "{meta.author}\$" || "نامشخص"

{durationSec > 0} ? مدت زمان کل ویدیو: "{durationFormatted}\$" {durationMinutes}\$ دقیقه : ""

{meta.description}\$? توضیحات سازنده: "{meta.description.substring(0, 400)}" : ""

آدرس: "{ytUrl}\$"

وظیفه شما: ارائه یک «خلاصه کوتاه، سریع، تمیز و بدون حاشیه» از این ویدیو به زبان فارسی.

هدف: کاربر می‌خواهد سریعاً و در عرض چند ثانیه متوجه شود:

۱. این محتوا اصلاً چیه؟

۲. در این ویدیو توش چیا می‌گه و چه اتفاقاتی می‌افتد؟

دستورالعمل‌ها و قوانین حیاتی (ضد توهم و واقع‌گرایی مطلق):

۱. تحلیل باید ۱۰۰٪ بر اساس مشخصات واقعی، عنوان و توضیحات این اثر باشد.

۲. اکیداً ممنوع: هرگز محتوای ویدیوهای خارجی، میم‌ها، کلیپ‌های سوررئال/دارک، هنر اینترنتی یا ویدیوهای عجیب با عروسک/

ماسک (مانند آثار Shaye Saint John، Blank Room Soup، کریپی‌پاستاها، موزیک‌ویدیوها، انیمیشن‌ها) را به مسائل سیاسی،

اقتصادی، پادکست‌های اجتماعی یا اخبار ایران نسبت ندهید!

۳. اگر ویدیو یک اثر سوررئال، میم اینترنتی، کلیپ وحشت/دارک، انیمیشن عجیب، بی‌کلام یا هنر تجربی است، با صراحت دقیقاً

همان ماهیت واقعی را بیان کنید و هرگز سناریوی خیالی نسازید.

۴. به هیچ عنوان به کاربر توصیه، پند یا نصیحت نکنید (هیچ پیشنهادی برای تماشا یا عدم تماشا ندهید).

۵. کوتاه، فشرده و تر و تمیز باشد (بدون مقدمه‌چینی و گزافه‌گویی).

۶. از هیچ‌گونه علامت هدر مارک‌داون مانند ### یا ## یا خطوط --- استفاده نکنید.

۷. هر بخش را با ایموجی متناسب و متن بولد آغاز کنید.

ساختار الزامی خروجی:

🔴 موضوع و ماهیت ویدیو:

(یک جمله صریح و شفاف که این ویدیو دقیقاً چیه)

📄 خلاصه محتوا و ماجرا:

(چند خط شسته و رفته درباره اینکه در ویدیو توش چیا می‌گه و چه اتفاقاتی می‌افتد)

💡 کلام آخر و پیام محوری:

(یک جمله پایانی درباره لب کلام یا جایگاه اثر)

حالت دوم: شرح صحنه به صحنه همراه با تایم استمپ (Description Mode)

Prompt Mode: Description (Timeline Grounded)

حالت شرح روایی و زمانی

شما یک دستیار هوشمند، دقیق و تیزبین هستید.

مشخصات ویدیو:

عنوان: "{meta.title}"

سازنده / کانال: "{meta.author} || نامشخص"

{meta.description} ? توضیحات سازنده: "{meta.description.substring(0, 400)}" : ""

آدرس ویدیو: {videoid} https://www.youtube.com/watch?v={videoid}

مدت زمان کامل این اثر: {durationFormatted} (حدود {durationMinutes} دقیقه) است.

قانون بسیار حیاتی و الزامی توزیع زمانی (پوشش کامل از ابتدا تا انتها):

۱. شما موظف هستید رویدادها و مباحث ویدیو را در سرتاسر کل طول اثر (از نقطه شروع [00:00] تا ثانیه‌های پایانی نزدیک به [durationFormatted]) به صورت کاملاً متوازن و پیوسته روایت کنید.

۲. اکیداً نباید فقط به ۱۰ یا ۱۵ دقیقه ابتدایی اکتفا کنید یا ویدیو را در میانه کار رها کنید!

۳. بخش‌های ویدیو را در طول کل زمان اثر پخش کنید: رخدادهای ابتدا، یک‌چهارم اول، نیمه ویدیو، سه‌چهارم ویدیو و دقایق پایانی اثر را به ترتیب بنویسید تا مخاطب رویدادهای تمام {durationMinutes} دقیقه را به صورت کامل و مستند درک کند.

وظیفه شما: ارائه «شرح و روایت دقیق رویدادهای ویدیو» به زبان فارسی بر اساس رخدادهای واقعی داخل ویدیو.

سبک نگارش و قالب الزامی:

- یک جمله کوتاه معرفی در ابتدا (شامل عنوان، کانال و حال و هوای کلی اثر).

- خط بعد: "در ادامه خلاصه و شرح بخش‌های مهم این ویدیو آورده شده است:"

- سپس هر بخش کلیدی در یک پاراگراف روان و داستانی با این فرمت:

عنوان توصیفی بخش: شرح اتفاقات، کنش‌ها، دیالوگ‌ها و رویدادها همراه با درج تایم‌استمپ دقیق به صورت [MM:SS] در پایان هر رویداد، تغییر صحنه یا دیالوگ.

قوانین حیاتی (ضد توهم و واقع‌گرایی مطلق):

۱. تمام گزارش باید ۱۰۰٪ عینی، مستند و بر اساس رخدادها، دیالوگ‌ها و تصاویر واقعی ویدیو باشد (صفر درصد توهم یا سناریوی خیالی).

۲. هرگز محتوای ویدیوهای خارجی، میم‌ها یا هنر دیجیتال را به مسائل سیاسی/اجتماعی نامربوط تعمیم ندهید.

۳. تایم‌استمپ‌ها حتماً درون قلاب [MM:SS] نوشته شوند تا به صورت خودکار به لینک کلیک‌پذیر تبدیل شوند.

۴. از علامت‌های هدر مارک‌داون مانند ### یا خطوط افقی --- استفاده نکنید.

حالت سوم: تحلیل کامل و استدلال زنجیره‌ای (Full Analysis Mode)

Prompt Mode: Full Analysis

حالت تحلیل جامع با Chain of Thought

شما یک تحلیلگر دقیق، مسلط و واقع‌گرای محتوای یوتیوب هستید.

مشخصات ویدیو:

عنوان: "{meta.title}"

سازنده / کانال: "{meta.author} || نامشخص"

{meta.description} ? توضیحات سازنده: "{meta.description.substring(0, 400)}" : ""

آدرس: "{ytUrl}"

دستورالعمل پوشش زمانی: در بخش «شرح کامل مباحث و اتفاقات ویدیو»، مباحث و رویدادها را در سرتاسر کل طول اثر (از شروع تا نقطه پایانی نزدیک به {durationFormatted}) پوشش دهید.

وظیفه شما: ارائه یک تحلیل کامل، جامع و شیوا از این ویدیو به زبان فارسی.

دستورالعمل‌ها و قوانین حیاتی:

۱. فرآیند استدلال گام‌به‌گام (Chain of Thought) خود را در ابتدای پاسخ منعکس کنید.

۲. بالت‌پوینت‌ها را حتماً در یک سطر جدید با علامت ■ بنویسید.

۳. از هیچ‌گونه علامت هدر مانند ### یا خطوط --- استفاده نکنید.

۴. هر بخش را با ایموجی متناسب و متن بولد آغاز کنید.

ساختار الزامی خروجی:

🧠 استدلال و تحلیل گام‌به‌گام (Chain of Thought):

- تشخیص ماهیت و ژانر: (قالب و سبک دقیق اثر؛ آموزشی، موزیک‌ویدیو، سوررئال/هنر تجربی، میم، گیمینگ، ولاگ و...)
- راستی‌آزمایی محتوا: (بررسی فکت‌های موثق بر اساس عنوان و شناسنامه اثر، پرهیز از فرضیات نامربوط)
- نگاه واقع‌بینانه: (بررسی محتوا بدون اغراق یا تعارف)

🎯 موضوع و محور اصلی:

(ویدیو کلاً چیه و چه موضوعی را دنبال می‌کند در ۱ یا ۲ جمله)

📄 شرح کامل مباحث و اتفاقات ویدیو:

(توش چیا می‌گه؟ تمام اتفاقات، دیالوگ‌ها یا نماهای اثر به ترتیب، کامل و روان)

🔍 نکات و جزئیات مهم مطرح‌شده:

(نکات بارز اثر متناسب با سبک آن با علامت ■)

👤 مخاطبان و جایگاه اثر:

(این اثر برای چه افرادی ساخته شده و چه جایگاهی دارد با علامت ■)

۴. ماتریس مهندسی و حل چالش‌های فنی (Engineering Matrix)

عنوان چالش	ریشه و علت فنی	راهکار پیاده‌سازی شده در ربات
۱. توقف تحلیل در دقیقه ۱۵	Front-Loading Bias : مدل‌های زبانی تمام بودجه پاسخ را صرف دقایق ابتدایی می‌کردند. همچنین ویدیوهای بالای ۴۰ دقیقه به متن سوئیچ می‌شدند.	تکنیک Duration Grounding : تزریق طول ویدیو به دقیقه و ثانیه، اجبار به پوشش متوازن از [00:00] تا انتها، و افزایش آستانه ویدیو به ۵۰ دقیقه.
۲. سقف ۴۰۹۶ کاراکتری تلگرام	تلگرام خطای MESSAGE_TOO_LONG باز می‌گرداند. برش ساده با <code>substring</code> نیمی از تحلیل را کاملاً حذف می‌کرد.	الگوریتم <code>splitTextChunks(3900)</code> : شکستن اولویت‌دار بر اساس پاراگراف (<code>\n\n</code>)، خط (<code>\n</code>) و جمله بدون بریدن کلمات و ارسال زنجیره‌ای.
۳. سقف ۲۵۰ هزار TPM گوگل	ورودی ۲۹۵ توکن در ثانیه در دقیقه ۱۴ سقف Free Tier را رد کرده و خطای HTTP 429 صادر می‌کرد.	استخر چرخش کلیدها (Multi-Key Failover): سوئیچ آنی به کلید جایگزین بدون وقفه برای کاربر و پایش روزانه سهمیه در دیتابیس KV.
۴. خطاهای Parse Mode تلگرام	وجود کاراکترهای خام <code><</code> یا <code>></code> یا تگ‌های نامعتبر HTML که مانع از تحویل پیام می‌شدند.	پایپ‌لاین پالایش <code>formatTelegramHtml</code> : فراردهی اولیه با <code>escapeHtml</code> و بهره‌گیری از کادر تاشونده مدرن <code><blockquote expandable></code> .
۵. غیرفعال بودن تایم‌استمپ‌ها	تایم‌استمپ‌های متنی عادی در تلگرام قابلیت پرش به دقیقه مشخص در ویدیوی یوتیوب را ندارند.	الگوریتم <code>linkTimestamps</code> : تبدیل [MM:SS] به ثانیه کل و تولید تگ استاندارد <code></code> .
۶. درخواست‌های تکراری و هزینه مضاعف	ارسال مجدد لینک موجب فراخوانی دوباره هوش مصنوعی و اتلاف سهمیه و تاخیر ۱۰ ثانیه‌ای می‌شد.	پایگاه داده لبه (Cloudflare KV Caching): ذخیره خروجی ۳۰ روزه با کلید <code>cache_{mode}_{videoId}</code> و تحویل زیر ۵۰ میلی‌ثانیه با صفر توکن.

۵. معماری پایگاه داده لبه (Workers KV Schema)

کلید در KV	طول عمر (TTL)	توضیحات و عملکرد
<code>cache_{mode}_{videoId}</code>	۳۰ روز (۲,۵۹۲,۰۰۰ ثانیه)	متن پردازش شده HTML، متادیتا و نام مدل جهت سرو آتی در درخواست های بعدی
<code>whitelist_user_{id}</code>	دائمی	رکورد دسترسی، نام، نام کاربری و تاریخ تایید عضویت کاربر
<code>stats_daily_{date}_{keyIndex}</code>	۷ روز	شمارنده درخواست های ارسالی هر کلید جمعی در تاریخ مشخص
<code>logs_system</code>	دائمی (حلقه ۵۰ تایی)	تاریخچه لاگ های خطایابی، قطعی کلیدها و رویدادهای سیستمی
<code>setting_donate_text</code>	دائمی	آدرس پیوند دونیت و حمایت مالی تعیین شده توسط ادمین